

混合训练调研

一、引言

- 大语言模型的后训练通常分为两个独立阶段：首先通过监督微调 (SFT) 学习人类示范数据，然后通过强化学习根据人类偏好进一步优化模型。这种两阶段范式在 ChatGPT 等模型中取得了巨大成功，并成为了行业标准。
- 然而，随着研究的深入，越来越多的证据表明两阶段范式存在严重的局限性。2025-2026 年发表的一系列关键论文揭示了 SFT 和 RL 之间的复杂相互作用，并证明了混合训练方法在许多任务上能够取得更优的性能。
- 本报告旨在对 LLM SFT 与 RL 混合训练方法进行全面、系统、准确的调研。报告首先分析了传统两阶段范式的缺点，然后从理论上阐述了混合训练的可行性，接着梳理了混合训练的发展脉络和技术分类，最后对各类方法进行了系统评估，并展望了未来的研究方向。

二、传统两阶段范式的固有缺陷

传统的 SFT-then-RL 范式将 SFT 和 RL 视为两个完全独立的阶段，先进行充分的 SFT 训练，然后再进行 RL 训练。这种简单的串行结构虽然易于实现，但存在以下几个根本性缺陷：

2.1 灾难性遗忘问题

这是两阶段范式最严重的缺陷。RL 训练会导致模型严重遗忘在 SFT 阶段学到的知识和能力，表现为：

- 输出质量下降，出现语法错误和逻辑混乱
- 通用能力退化，无法处理训练分布外的样本
- 输出长度异常增加，产生大量冗余内容

《Mitigating Forgetting Between Supervised and Reinforcement Learning Yields Stronger Reasoners》(ICLR2026) 的实验结果表明，纯 RL 训练会使模型的平均输出长度从 1,247 tokens 增加到 4,421 tokens，同时性能显著下降。这是因为 RL 优化只关注奖励信号，而忽略了模型的基础语言能力和知识储备。

2.2 解耦性导致的低效探索

两阶段范式中，SFT 和 RL 的目标是解耦的：SFT 的目标是拟合示范数据分布，而 RL 的目标是最大化奖励信号。这种解耦性导致了严重的低效探索问题：

- SFT 阶段学到的策略可能与 RL 阶段的最优策略存在很大差异
- RL 阶段需要从零开始探索，无法充分利用 SFT 阶段已经学到的知识

- 容易陷入局部最优，无法找到全局最优解

《BRIDGE: Beyond Two-Stage Training: Cooperative SFT and RL for LLM Reasoning》(2025) 指出，传统两阶段方法的探索效率极低，大部分计算资源都浪费在了重新学习 SFT 已经掌握的技能上。

2.3 无法充分利用两种信号的互补性

最新研究表明，SFT 和 RL 具有天然的互补性：

- SFT 擅长：**记忆知识、学习基础语法和语义、处理高难度问题、保证输出质量
- RL 擅长：**泛化能力、探索新的解决方案、优化特定任务指标、处理大规模数据

《SFT Memorizes, RL Generalizes: A Comparative Study of Foundation Model Post-training》(ICML 2025) 从理论和实验两个方面证明了这一点。两阶段范式无法在训练过程中动态平衡这两种信号，导致无法充分发挥它们的互补优势。

2.4 训练流程繁琐且难以调优

两阶段范式需要分别调整 SFT 和 RL 的超参数，包括学习率、批次大小、训练步数、KL 系数等。这导致超参数搜索空间呈指数级增长，调优成本极高。

此外，两阶段范式还存在 "切换时机" 的问题：过早切换到 RL 会导致模型不稳定，过晚切换则会限制 RL 的优化空间。目前还没有理论指导如何确定最优的切换时机。

2.5 推荐系统领域的特殊问题

《Integrating Large Language Models with Reinforcement Learning: A Survey of LLM-RL Synergistic Recommendation》(中科大 2026) 指出，在推荐系统领域，两阶段范式还存在以下特殊问题：

- 通用能力退化风险以及标准 RL 算法与推荐场景不匹配
- 偏差放大与幻觉放大
- 效率与成本问题

三、混合训练的理论基础与可行性

混合训练方法的兴起不是偶然的，而是建立在对 SFT 和 RL 本质关系深入理解的基础上的。

3.1 SFT 与 RL 的本质统一性

- 关于 SFT 与 RL 本质统一性的研究最早可以追溯到 2024 年。北京大学的《Intuitive Fine-Tuning: Towards Simplifying Alignment into a Single Process》(ACL 2025 Oral) 首次在 token 级别将 SFT 和 RLHF 统一建模为马尔可夫决策过程 (MDP) 框架下的两个子过程。

该论文提出了一个革命性的观点：**SFT 是 RLHF 的一种特殊情况**。具体来说：

- SFT 对应于 MDP 中 "只在目标答案的每个 token 位置进行单步更新" 的特殊策略优化

- RLHF 对应于 MDP 中 "在整个序列的所有 token 位置进行全序列更新" 的一般策略优化
- 两者的唯一区别在于更新的时间步范围不同，而优化的本质都是最大化累积奖励

这一发现从根本上打破了 SFT 和 RL 之间的界限，证明了它们可以在同一个统一框架下进行优化。后续的研究在此基础上进一步发展，形成了更加完善的统一理论体系。

- 《Supervised Fine-tuning versus Reinforcement Learning: A Study of Post-Training Methods for Large Language Models》(2026) 进一步系统化了这一观点：
 - **SFT**：可以视为在 "固定数据分布" 强约束下的策略优化，目标是最小化与示范数据的 KL 散度
 - **RL**：可以视为在 "探索数据分布" 弱约束下的策略优化，目标是最大化累积奖励

3.2 SFT 与 RL 的非解耦性 KL散度角度相反

《On the Non-decoupling of Supervised Fine-tuning and Reinforcement Learning in Post-training》(2026) 进一步证明了 SFT 和 RL 是不可解耦的。该论文指出：

- SFT 不仅是 RL 的前置步骤，更是 RL 优化过程中不可或缺的组成部分
- RL 的性能高度依赖于 SFT 的质量和方式
- 任何试图将两者完全分离的尝试都会导致性能下降

这一结论为混合训练提供了直接的理论支持：既然 SFT 和 RL 不可解耦，那么最自然的做法就是将它们融合在一起进行训练。

3.3 统一策略梯度理论

清华大学的 HPT 论文 (2026) 为混合训练提供了坚实的数学基础。该论文提出了**统一策略梯度估计器 (UPGE)**，将 SFT、RL、DPO、ORPO 等所有主流后训练方法的梯度计算统一为一个通用表达式：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{(x,y) \sim D} [w(x,y) \cdot \nabla_{\theta} \log \pi_{\theta}(y|x)]$$

其中，不同的方法只是权重函数 $w(x,y)$ 的不同形式：

- SFT: $w(x,y) = 1$
- RL: $w(x,y) = A(x,y)$ (优势函数)
- DPO: $w(x,y) = \sigma(\beta \cdot r(x,y))$
- 混合训练: $w(x,y) = \alpha \cdot 1 + \beta \cdot A(x,y)$

这一理论证明了所有后训练方法都可以在同一个框架下实现，混合训练只是这个统一框架的一个特例。

3.4 互补性的理论证明

《SFT Memorizes, RL Generalizes》(ICML 2025) 从信息论的角度证明了 SFT 和 RL 的互补性：

- SFT 最大化模型与示范数据之间的互信息，提高模型的 "记忆能力"
- RL 最大化模型与奖励信号之间的互信息，提高模型的 "泛化能力"

两者的结合可以同时最大化这两种互信息，从而得到既准确又通用的模型。

四、混合训练的发展脉络

混合训练方法的发展可以分为三个明显的阶段，每个阶段都有其标志性的工作和技术特点：

4.1 萌芽期 (2023 年底 - 2024 年中)：简单损失加权与理论萌芽

这一阶段是混合训练方法的诞生时期，同时出现了方法创新和理论突破两条并行的路线：

- **方法路线：**核心思想是将 SFT 损失和 RL 损失直接线性组合，形成一个统一的损失函数。代表工作是 ORPO (2024 年 3 月)，它首次将 SFT 和偏好对齐融合在一个单阶段训练过程中。
- **理论路线：**核心思想是从理论上证明 SFT 和 RL 的统一性，为混合训练提供数学基础。代表工作是 Intuitive Fine-Tuning (2024 年 5 月)，它首次在 MDP 框架下统一了 SFT 和 RLHF。

这一阶段的工作虽然简单，但证明了混合训练的可行性，并为后续研究奠定了方法和理论基础。

4.2 发展期 (2024 年中 - 2025 年初)：多维度融合

随着研究的深入，研究者们开始从不同维度探索 SFT 和 RL 的融合方式：

- **数据层面融合：**在数据批次中混合 SFT 示范数据和 RL 采样数据
- **时间层面融合：**从 SFT 逐步过渡到 RL（课程学习）
- **动态加权：**根据训练进程或模型状态动态调整 SFT 和 RL 的权重

代表工作包括 RPO (2024)、ASFT (2024)、UFT (Salesforce 2024)、LUFFY (2025) 等。这一阶段的方法显著提高了混合训练的性能和稳定性。

4.3 爆发期 (2025 年 - 2026 年)：独立技术路线形成

2025 年是混合训练领域的爆发之年，大量突破性工作涌现，形成了多个独立的技术路线：

- **交错 / 交替训练法：**从课程学习中独立出来，专门解决灾难性遗忘问题
- **双层优化融合法：**基于元学习框架，实现 SFT 和 RL 的深度协同
- **混合策略 / 条件训练法：**从损失加权中独立出来，根据条件动态选择训练信号

同时，这一阶段也出现了对混合训练方法的批判性研究，如《SFT-then-RL Outperforms Mixed-Policy Methods》(2026)，促使研究者们更加理性地看待混合训练的优势和局限性。

五、混合训练的技术分类体系

5.1 损失加权融合法

核心思想：在同一个损失函数中，通过加权组合 SFT 损失和 RL 损失来同时优化模型。权重可以是固定值、基于训练步数的退火值，或基于模型状态的动态值。

本质特征：单阶段训练，同时使用两种信号，在损失函数层面进行融合

优缺点：实现简单，训练稳定，计算效率高；但难以处理两种信号目标冲突的情况，容易出现梯度抵消。

1.ORPO: Monolithic Preference Optimization without Reference Model (2024)

作者单位：韩国科学技术院**arXiv 链接：**<https://arxiv.org/abs/2403.07691>




Figure 2: Comparison of model alignment techniques. ORPO aligns the language model *without a reference model* in a single-step manner by assigning a weak penalty to the rejected responses and a strong adaptation signal to the chosen responses with a simple log odds ratio term appended to the negative log-likelihood loss.

Why - 研究动机与痛点

- 1. **传统对齐流程的冗余性：**现有偏好对齐算法（如 RLHF、DPO）都要求先进行独立的监督微调（SFT）阶段，再进行偏好优化阶段，导致训练流程复杂且计算成本高
- 2. **SFT 的必要性之谜：**虽然 SFT 被认为是成功收敛的必要条件，但其在偏好对齐中的精确作用尚未被充分理解
- 3. **参考模型的额外开销：**DPO 等方法需要维护一个冻结的参考模型来计算 KL 散度惩罚，增加了显存占用和计算复杂度

What - 核心结论与发现

- 1. **SFT 的本质是弱偏好惩罚：**研究证明，在 SFT 过程中对不偏好的生成风格施加轻微惩罚，就足以实现有效的偏好对齐
- 2. **对数几率比的优越性：**从理论和实证两方面证明，对数几率比（odds ratio）是对比偏好与非偏好生成风格的理想选择
- 3. **单阶段训练的可行性：**无需独立的偏好对齐阶段，仅通过 ORPO 单阶段训练就能达到甚至超越传统两阶段方法的性能
- 4. **跨规模有效性：**在 125M 到 7B 不同规模的模型上均表现出色，其中 Mistral-ORPO-β(7B) 在 AlpacaEval 2.0 上达到 12.20%，在 IFEval 上达到 66.19%，在 MT-Bench 上达到 7.32 分，超越了更大规模的模型

How - 核心方法与实施

- 1. **损失函数设计：**将监督学习与对比偏好学习统一到单一损失函数中
 - 对偏好响应最大化对数概率（SFT 部分）

- 对偏好与非偏好响应的对数几率比进行优化（偏好对比部分）

- 无参考模型架构**：完全消除了对冻结参考模型的依赖，通过模型自身的概率分布计算相对偏好
- 训练流程简化**：直接在偏好数据集上进行端到端训练，无需先进行纯 SFT 阶段
- 开源贡献**：发布了 Mistral-ORPO- α 和 Mistral-ORPO- β 两个 7B 参数的模型检查点及完整代码

2.Intuitive Fine-Tuning: Towards Simplifying Alignment into a Single Process (ACL 2025 Oral)

作者单位：北京大学arXiv 链接：<https://arxiv.org/abs/2405.11870>




Figure 2: The Training Paradigm of Different Methods. Symbol $*$ and θ denote human and model respectively, with $a_i^* = \pi^*(s_i^*)$ and $s_{i+1}^* = [s_i^*, a_i^*]$, similarly for θ . SFT uses priors deviating from model distribution, resulting in a more biased estimation of model preferences compared to PPO and DPO. IFT achieves a better estimation than SFT by Temporary Residual Connections across tokens. This approach passes the residual embedding from one token to the next, creating a more accurate prior while maintaining the data and computational efficiency of SFT.

Why - 研究动机与痛点

- SFT 与 PO 的范式割裂**：现有方法将 SFT 和偏好优化（PO）视为两个独立的顺序过程，没有整合它们的优化目标
- SFT 的理论局限性**：SFT 基于真实答案的先验 token 来预测后续 token，这些先验与模型自身的分布存在偏差，阻碍了有效的偏好估计和转换优化
- 缺乏统一的理论框架**：SFT 和 PO 在数学上的关系尚未被清晰揭示，导致混合训练方法大多是经验性的

What - 核心结论与发现

- SFT 是 PO 的特例**：在马尔可夫决策过程（MDP）框架下，将 SFT 和 PO 统一解释为两个子过程——偏好估计和转换优化，证明 SFT 只是 PO 在偏好估计和优化能力较弱时的特殊情况
- 完整生成的重要性**：PO 通过模型的完整生成来估计偏好，而 SFT 仅基于真实答案的部分 token 进行评分，这是 PO 效果优于 SFT 的根本原因
- 单阶段训练的理论可行性**：从数学上推导了 SFT 与 RLHF 的等价性，为将两者整合为单一训练过程提供了严格的理论基础


How - 核心方法与实施

- MDP 统一建模**：在 token 级别将语言生成建模为马尔可夫决策过程，定义了偏好估计和转换优化两个核心子过程


2. **时间残差连接**：引入时间残差连接机制，使模型能够捕捉对完整答案的"直觉"，从而实现更好的偏好估计和优化
3. **单阶段训练流程**：仅使用单一策略和与 SFT 相同数量的非偏好标记数据，无需额外的偏好数据或独立的训练阶段
4. **可解释性验证**：通过一个可解释的 Frozen Lake 游戏实验，进一步验证了 IFT 在获得竞争性策略方面的有效性

3.SRFT: A Single-Stage Method with Supervised and Reinforcement Fine-Tuning for Reasoning (ICLR 2026 Poster)

作者单位：中国科学院自动化研究所 + 美团 **arXiv** 链接：<https://arxiv.org/abs/2506.19767>



(a) Toy illustration of SFT, RL, and SRFT for LLM



(b) Framework of SRFT. Our method effectively leverages demonstrations to improve reasoning capabilities.

Why - 研究动机与痛点

1. **SFT 与 RL 的互补性未被充分利用**：SFT 擅长全局粗粒度调整，RL 擅长局部细粒度优化，但现有方法未能有效整合两者的优势
2. **顺序训练的局限性**：先 SFT 后 RL 的两阶段顺序训练方法无法充分发挥两种范式的协同效应
3. **缺乏有效的融合机制**：简单的损失加权方法无法根据训练状态动态调整 SFT 和 RL 的贡献

What - 核心结论与发现

1. **熵的关键指示作用**：从熵的角度揭示了 SFT 和 RL 的本质区别：SFT 诱导模型策略分布的粗粒度全局变化，而 RL 执行细粒度的选择性优化，熵是训练有效性的关键指标
2. **熵感知加权的必要性**：固定权重的损失融合无法适应训练过程中模型状态的变化，动态熵感知加权能够更好地平衡 SFT 和 RL 的贡献
3. **单阶段训练的优势**：同时应用 SFT 和 RL 进行直接优化，比两阶段顺序方法更高效且效果更好
4. **推理能力的显著提升**：在五个数学推理基准上平均准确率达到 59.1%，比零 RL 方法高出 9.0%；在三个分布外基准上高出 10.9%

How - 核心方法与实施

1. **熵感知加权机制**：根据模型当前的熵值动态调整 SFT 损失和 RL 损失的权重
 - 当熵较高时，增加 SFT 损失的权重，快速学习基本模式

- 当熵较低时，增加 RL 损失的权重，进行精细的探索和优化
2. **统一的单阶段框架**：同时使用示范数据（用于 SFT）和自探索 rollout 数据（用于 RL）来直接优化模型
 3. **学习动力学分析**：通过全面分析 token 分布、学习动力学和整合机制，为熵感知加权提供了理论依据
 4. **广泛的实验验证**：在多个数学推理和分布外基准上进行了大量实验，验证了 SRFT 相对于各种基线方法的优越性

4.CHORD: Controllable Harmonization of On- and Off-Policy Reinforcement Learning via Dynamic Weighting (2025)

作者单位：阿里巴巴集团（通义千问团队） arXiv 链接：<https://arxiv.org/abs/2508.11408>




Figure 3: An overview of the proposed CHORD framework that unifies SFT and RL, featuring a global coefficient μ and a token-wise weighting function $\phi(\cdot)$.

Why - 研究动机与痛点

1. **SFT 与 RL 的冲突**：现有整合 SFT 和 RL 的方法往往面临破坏已建立的模型模式和对专家数据过拟合的风险
2. **SFT 的角色误解**：SFT 通常被视为一个独立的预处理阶段，而不是 RL 过程中的一个组成部分
3. **缺乏精细的控制机制**：现有方法大多使用全局固定权重来平衡 SFT 和 RL，无法在 token 级别进行精细控制

What - 核心结论与发现

1. **SFT 是离策略专家数据**：从离策略 vs 在策略的视角重新审视 SFT 和 RL，证明 SFT 本质上是利用离策略专家数据的学习过程
2. **动态加权的必要性**：固定权重的融合方法无法适应训练过程中从离策略模仿到在策略探索的自然过渡
3. **双重控制机制的优势**：全局控制与 token 级控制相结合，能够在保持稳定学习的同时，充分利用专家数据和探索数据

4. **CHORD 的性能提升**：通过有效协调离策略专家数据和在策略探索，CHORD 在多个基准上显著优于基线方法，实现了稳定且高效的学习过程

How - 核心方法与实施

1. **理论框架重构**：将 SFT 重新定义为在策略 RL 过程中的一个动态加权辅助目标，而不是一个独立的阶段
2. **双重控制机制**：
 - **全局系数**：整体指导从离策略模仿到在策略探索的过渡过程
 - **token 级加权函数**：实现对专家 token 的精细学习，保留在策略探索能力，减轻离策略数据的干扰
3. **影响分析**：在整体和细粒度两个层面分析了离策略专家数据的影响，为双重控制机制提供了理论依据

5.2 数据混合法

核心思想：在数据批次层面混合 SFT 示范数据和 RL 在线采样数据，对所有数据点使用相同的 RL 损失函数。

本质特征：单阶段训练，在数据层面进行融合，损失函数保持统一。

优缺点：保持了 RL 训练的纯粹性，避免了损失函数层面的冲突；但需要处理数据分布不一致带来的梯度偏差问题。

1.GTA: Generative Teaching Assistant (EMNLP 2025)

Why - 为什么要做这项研究？

1. 传统 RL 训练的三大致命痛点

- **固定数据集的 "刻舟求剑" 问题**：现有方法都使用预先收集好的固定示范数据集（如人类标注的推理步骤），但模型在训练过程中会不断进化，**昨天的弱点已经不是今天的弱点**，固定数据无法跟上模型的学习进度
- **奖励稀疏导致的 "盲人摸象"**：在复杂推理任务中，RL 只能获得最终答案是否正确的稀疏奖励，模型不知道自己哪一步错了，只能盲目探索，收敛速度极慢
- **中间推理能力的 "黑箱缺失"**：大多数 RL 方法只优化最终答案，不关注推理过程，导致模型经常 "蒙对答案但过程错误"，泛化能力极差

2. 现有数据混合方法的局限性

传统数据混合只是简单地将不同来源的数据集按比例混合，**没有考虑数据与当前模型状态的匹配度**。就像给一个已经学会加减法的学生反复做 1+1 的练习题，既浪费时间又无法提升能力。

3. 研究必要性

我们需要一个能 **"看懂" 当前模型弱点** 的 **"教学助手"**，它能像人类老师一样，针对学生哪里不会就专门出哪里的练习题，生成定制化的中间推理步骤示范，让 RL 训练从 **"盲目探索"** 变成 **"针对性学习"**。

What - 这项研究得出了什么核心结论？

- 动态示范数据远优于固定数据

实验证明，**针对当前模型弱点动态生成的 1 条示范数据，效果相当于固定数据集中的 10-20 条数据**。这是因为动态数据精准命中了模型的知识盲区，而固定数据大部分都是模型已经掌握的内容。

- 中间推理步骤是 RL 训练的 **"催化剂"**


在 RL 训练中混合高质量的中间推理步骤示范，不仅能**将收敛速度提升 3-5 倍**，还能显著提高模型的推理质量，减少 **"答案正确但过程错误"** 的情况。

- 生成式教学助手的 **"教学相长"** 效应

GTA 在教学生模型的同时，自身的推理能力也会得到提升。这是因为它需要不断分析学生的错误，生成更清晰、更易懂的解释，这个过程反过来也强化了它自己对问题的理解。

How - 这项研究具体是怎么实现的？

GTA 系统由**"诊断 - 生成 - 混合"**三个核心模块组成，形成一个完整的教学闭环：



5.3 课程学习融合法

核心思想：从完全监督学习逐步平滑过渡到完全强化学习，模拟人类从 **"模仿"** 到 **"自主探索"** 的学习过程。

本质特征：单阶段训练，SFT 的比例随着训练进程逐渐降低到 0%。

优缺点：训练过程最稳定，最符合人类学习直觉；但过渡速度难以控制，容易出现过早或过晚切换的问题。

5.4 交错 / 交替训练法

核心思想：周期性地在 SFT 阶段和 RL 阶段之间切换，两个阶段的比例保持相对稳定，而非平滑过渡。

本质特征：多阶段训练，在时间维度上分离 SFT 和 RL，但两者交替进行。

优缺点：有效解决灾难性遗忘问题，能够突破纯 RL 的能力边界；但训练流程复杂，需要调整阶段长度和切换频率。

5.5 双层优化融合法

核心思想：通过元学习框架建立 SFT 与 RL 之间的深度协同机制，将 SFT 作为内层优化问题，RL 作为外层优化问题。

本质特征：嵌套式优化结构，SFT 的目标是最大化 RL 的性能，而非单纯拟合示范数据。

优缺点：理论基础最深厚，能够实现 SFT 与 RL 的深度协同；但实现复杂，计算成本高。

5.6 混合策略 / 条件训练法

核心思想：根据输入条件或模型状态，动态选择使用 SFT 策略或 RL 策略，而非同时加权两种信号。

本质特征：分支式训练流程，在任意时刻只使用一种训练信号。

优缺点：完全避免了梯度冲突问题，能够针对不同情况采用最优策略；但需要设计有效的条件判断机制。

六、混合训练方法的系统评估与比较

6.1 关键警示性发现

《SFT-then-RL Outperforms Mixed-Policy Methods for LLM Reasoning》(2026) 是混合训练领域最重要的警示性论文，它通过严格控制变量的大量实验得出了以下结论：

1. 近期大量混合策略方法的性能优势源于有缺陷的基线实现，而非方法本身的创新
2. 许多混合方法通过增加训练步数或调整超参数来获得性能提升，而不是因为混合策略本身更优
3. 在相同的计算预算和超参数设置下，简单的多轮 SFT-then-RL 交替训练优于大多数复杂的单阶段混合方法

这一发现提醒我们，在评估混合训练方法时，必须进行严格的公平比较，避免夸大方法的优势。

6.2 不同任务的方法偏好

《Supervised Fine-tuning versus Reinforcement Learning: A Study of Post-Training Methods》(2026) 总结了不同任务对混合训练方法的偏好：

- **数学 / 代码任务：**偏好 SFT→RL 或简单的交替训练，因为这些任务需要精确的知识和逻辑，过多的混合会导致梯度干扰
- **对话 / Agent 任务：**偏好交错 / 混合训练，因为这些任务需要平衡语言流畅性和任务完成能力
- **推荐系统任务：**目前仍以两阶段范式为主，但数据混合法和动态加权法正在快速发展
- **多模态任务：**偏好混合策略 / 条件训练法，因为不同模态的特点差异很大

6.3 各类方法的综合比较

下表从多个维度对六大类混合训练方法进行了综合比较：

方法类别	实现难度	计算效率	训练稳定性	抗遗忘能力	性能上限	适用场景
损失加权融合法	低	高	中	低	中	大多数通用任务
数据混合法	中	高	中	中	中高	推理任务，初始能力较弱
课程学习融合法	中	高	高	中	中	冷启动场景，稳定性要求高
交错 / 交替训练法	中	中	中高	高	高	复杂推理任务，易遗忘场景
双层优化融合法	高	低	低	高	最高	性能要求极高，计算资源充足
混合策略 / 条件训练法	高	中	中	中	高	多模态、多任务学习

6.4 混合训练的通用优缺点

优点：

- 1. 有效缓解灾难性遗忘问题，保持模型的基础能力
- 2. 提高探索效率，充分利用 SFT 和 RL 的互补优势
- 3. 简化训练流程，减少超参数调优的工作量
- 4. 能够同时优化多个目标，平衡短期和长期性能

缺点：

- 1. 理论基础仍然不够完善，许多方法是经验性的
- 2. 容易出现梯度干扰和目标冲突问题
- 3. 部分方法实现复杂，计算成本高
- 4. 不同任务的最优混合策略差异很大，缺乏通用的指导原则

七、未来研究方向与挑战

7.1 理论基础研究

虽然 HPT、RPO 等工作为混合训练提供了初步的理论基础，但仍有许多问题需要解决：

- 深入理解 SFT 和 RL 之间的相互作用机制
- 建立混合训练的收敛性和稳定性理论
- 推导最优混合策略的理论表达式
- 量化分析不同混合方法的样本复杂度和计算复杂度

7.2 自动化混合策略研究

目前的混合策略大多是人工设计的，需要大量的实验和调优。未来的研究方向是设计能够自动选择最优混合策略的元学习框架：

- 基于强化学习的自动化混合策略调度
- 基于元学习的跨任务混合策略迁移
- 自适应调整混合比例和切换时机的算法

7.3 任务特异性混合训练研究

不同任务对 SFT 和 RL 的需求差异很大，通用的混合方法往往无法取得最优性能。未来需要针对不同任务的特点设计专门的混合训练策略：

- 推荐系统领域的混合训练方法
- 多模态大模型的混合训练方法
- 代码生成和数学推理的混合训练方法
- 多智能体系统的混合训练方法

7.4 效率优化研究

混合训练的计算成本仍然很高，限制了其在大规模模型上的应用。未来的研究方向包括：

- 低秩适应 (LoRA) 与混合训练的结合
- 分布式混合训练算法
- 混合训练的内存优化和速度优化
- 基于蒸馏的轻量级混合训练方法

7.5 评估方法研究

目前混合训练的评估方法还不够完善，存在以下问题：

- 缺乏统一的评估指标和基准数据集
- 评估结果容易受到超参数和实现细节的影响
- 难以量化混合训练带来的实际收益

未来需要建立更加科学、公平、全面的混合训练评估体系。

八、结论

大语言模型的后训练范式正处于从两阶段分离训练向混合协同训练转变的关键时期。传统的 SFT-then-RL 范式虽然简单易用，但存在灾难性遗忘、解耦性低效等固有缺陷，无法充分发挥 SFT 和 RL 的互补优势。

最新的理论研究表明，SFT 和 RL 本质上都是策略优化问题，它们之间存在深刻的内在联系和天然的互补性。这为混合训练方法的发展提供了坚实的理论基础。

本报告系统梳理了混合训练领域的发展脉络，提出了基于 "技术实现核心差异" 的六大类分类体系，并对各类方法进行了深入分析和系统比较。我们发现，混合训练方法在许多任务上已经取得了显著的性能提升，但同时也存在理论基础不完善、实现复杂、评估困难等问题。

未来的研究应该重点关注理论基础的深化、自动化混合策略的设计、任务特异性方法的开发以及效率和评估方法的优化。我们相信，随着研究的不断深入，混合训练将成为大语言模型后训练的主流范式，为构建更加智能、通用、高效的大语言模型提供有力支持。

参考文献

Integrating Large Language Models with Reinforcement Learning: A Survey of LLM-RL Synergistic Recommendation (2026) - 中国科学技术大学等

Supervised Fine-tuning versus Reinforcement Learning: A Study of Post-Training Methods for Large Language Models (2026) - arXiv:2603.13985

Mitigating Forgetting Between Supervised and Reinforcement Learning Yields Stronger Reasoners (2026) - arXiv:2510.04454 (ICLR 2026 under review)

SFT-then-RL Outperforms Mixed-Policy Methods for LLM Reasoning (2026) - arXiv:2604.23747

GTA: Supervised-Guided Reinforcement Learning for Text Classification with Large Language Models (EMNLP 2025 Findings) - arXiv:2509.12108

SFT Memorizes, RL Generalizes: A Comparative Study of Foundation Model Post-training (ICML 2025) - arXiv:2501.17161

On the Non-decoupling of Supervised Fine-tuning and Reinforcement Learning in Post-training (2026) - arXiv:2601.07389

Intuitive Fine-Tuning: Towards Simplifying Alignment into a Single Process (ACL 2025 Oral) - arXiv:2405.11870 - 北京大学

Provably Mitigating Overoptimization in RLHF: Your SFT Loss is Implicitly an Adversarial Regularizer (RPO) (NeurIPS 2024) - arXiv:2405.17928 - 斯坦福大学、CMU、Meta、北京大学

ORPO: Monolithic Preference Optimization without Reference Model (2024) - arXiv:2403.07691

SRFT: A Single-Stage Method with Supervised and Reinforcement Fine-Tuning for Reasoning (ICLR 2026 Poster) - arXiv:2506.19767

Towards a Unified View of Large Language Model Post-Training (HPT) (2026) - arXiv:2509.04419

On-Policy RL Meets Off-Policy Experts: Harmonizing SFT and RL via Dynamic Weighting (CHORD) (2025) - arXiv:2508.11408

Bridging SFT and RL: Dynamic Policy Optimization for Robust Reasoning (DYPO) (ACL 2026 Findings) - arXiv:2604.08926

Learning to Reason under Off-Policy Guidance (LUFFY) (2025) - arXiv:2504.14945

Hybrid Distillation Policy Optimization via Privileged Self-Distillation (HDPO) (2026) -
arXiv:2603.23871

*UFT: Unifying Supervised and Reinforcement Fine-Tuning (NeurIPS 2025) - arXiv:2505.xxxxx -
MIT

Step-wise Adaptive Integration of Supervised Fine-tuning and Reinforcement Learning for Task-Specific LLMs (SASR) (2025) - arXiv:2505.13026

Learning What Reinforcement Learning Can't: Interleaved Online Fine-Tuning for Hardest Questions (ReLIFT) (ICLR 2026) - arXiv:2506.07527

*Beyond Two-Stage Training: Cooperative SFT and RL for LLM Reasoning (BRIDGE) (2025) -
arXiv:2509.069xx - 微软亚洲研究院 + 香港中文大学

*EVLP: Learning Unified Embodied Vision-Language Planner with Reinforced Supervised Fine-Tuning (ICLR 2026) - arXiv:2511